Regression_Lineaire

October 31, 2026

FORMATION MED_IA: ANALYSE DE DONNEES

1 Chapitre 2 : REGRESSION LINEAIRE

1.1 Définition

La régression linéaire est une méthode statistique de modélisation dont l'objectif est d'exprimer une variable quantitative dépendante (notée Y, dite variable expliquée) sous la forme d'une fonction affine d'une ou plusieurs variables indépendantes (notées X_i, dites variables explicatives), à laquelle s'ajoute un terme d'erreur aléatoire (noté ε) **(Gilbert Saporta, 2011).**

Dans son expression mathématique théorique, le modèle s'écrit :

$Y=\beta_0+\beta_1 X_1+\beta_2 X_2+...+\beta_k X_k+\varepsilon$

La détermination des coefficients β_i repose le plus souvent sur la méthode des moindres carrés ordinaires (MCO), qui consiste à minimiser la somme des carrés des résidus (les écarts entre les valeurs observées de Y et les valeurs prédites par le modèle).

1.2 Les hypothèses de la régression linéaire

1.2.1 Linéarité du modèle et spécification

Hypothèse: La relation entre la variable dépendante Y et les variables explicatives X_i est strictement linéaire dans ses paramètres β_i. Le modèle ne souffre d'aucune omission de variable pertinente ni de mauvaise forme fonctionnelle.

Méthode de vérification de l'hypothèse

- Méthode graphique

Le graphique des résidus en fonction des valeurs prédites $\hat{Y}$. Les points doivent se répartir de manière aléatoire autour de la ligne horizontale zéro, sans former de courbe (comme un "U" ou un arc).

- Test statistique

Le test de spécification de Ramsey (RESET). Il vérifie si des puissances non linéaires des variables comme X^2 ou X^3 expliqueraient significativement mieux la variable Y.

1.2.2 Absence de multicolinéarité parfaite

Hypothèse: Les variables explicatives X_i ne sont pas linéairement dépendantes les unes des autres. Il n'y a pas de corrélation parfaite entre deux variables indépendantes sinon, il est mathématiquement impossible de calculer l'inverse de la matrice des données pour obtenir les coefficients).

Méthode de vérification de l'hypothèse

- Méthode graphique / Matricielle

La matrice de corrélation entre toutes les variables explicatives. Des coefficients supérieurs à 0,7 ou 0,8 signalent un risque de colinéarité.

- Test statistique

Le VIF (Variance Inflation Factor) ou Facteur d'Inflation de la Variance.

Un VIF > 5 ou 10 (selon la sévérité du critère choisi) indique une colinéarité problématique qui nécessite de retirer ou de combiner une variable.

1.2.3 Exogénéité stricte (Espérance nulle des erreurs)

Hypothèse : L'espérance mathématique du terme d'erreur est nulle pour toutes les observations : $E(\varepsilon_i|X) = 0$. Cela signifie que les variables explicatives ne contiennent aucune information sur l'erreur et qu'il n'y a pas de corrélation entre les X et l'erreur.

Méthode de vérification de l'hypothèse

- Méthode théorique

L'exogénéité se vérifie d'abord par la structure logique du modèle (absence de causalité inverse ou de variable omise importante).

- Test statistique

Le test d'Hausman. Il permet de comparer l'estimateur MCO à un estimateur par variables instrumentales (VI) afin de détecter si une variable explicative est corrélée avec le terme d'erreur (endogénéité).

1.2.4 Homoscédasticité (Variance constante)

Hypothèse : La variance du terme d'erreur est constante pour toutes les observations : $V(\varepsilon_i) = \sigma^2$.

En d'autres termes, la dispersion des résidus reste la même, quel que soit le niveau des variables explicatives.

Méthode de vérification de l'hypothèse

- Méthode graphique

Le graphique des résidus standardisés en fonction des valeurs prédites. La dispersion verticale des points doit rester globalement constante d'un bout à l'autre du graphique (pas de forme d'entonnoir ou d'éventail).

- Tests statistiques

Le test de Breusch-Pagan sensible aux relations linéaires de la variance.

Le test de White détecte aussi les formes non linéaires de l'hétéroscédasticité.

1.2.5 Absence d'autocorrélation des erreurs

Hypothèse : Les termes d'erreur de deux observations distinctes sont indépendants (non corrélés) : $Cov(\varepsilon_i, \varepsilon_j) = 0$ pour tout $i \neq j$. Cette hypothèse est particulièrement cruciale pour les données chronologiques ou séries temporelles.

Méthode de vérification de l'hypothèse

- Méthode graphique

Le graphique des résidus au cours du temps (ordre des observations) ou le corrélogramme (ACF) des résidus.

- Tests statistiques

Le test de Durbin-Watson : Utilisé spécifiquement pour l'autocorrélation d'ordre 1 dans les séries temporelles. Une valeur proche de 2 indique l'absence d'autocorrélation.

Le test de Breusch-Godfrey (ou test LM) : Il permet de tester des autocorrélations d'ordres supérieurs (plusieurs décalages temporels).

1.2.6 PRATIQUE DE LA REGRESSION LINEAIRE DANS PYTHON

- PANDAS: pour l'importation du jeu de données
- Matplotlib: pour la visualisation des données
- Sklearn : pour modélisation des modèles de machine learning

- Statsmodels: pour l'analyse statistique

Rappel relatif au motif Sklearn

1.2.7 Les 4 outils de Sklearn indispensables pour l'analyse de données

Le découpage des données (sklearn.model_selection) En Machine Learning, on ne teste jamais un modèle sur les mêmes données qui ont servi à l'entraîner (ce serait comme donner à un étudiant l'examen avec les réponses la veille). On sépare la base de données Pandas en deux : une partie pour l'entraînement (ex: 80%) et une partie pour le test (ex: 20%).**La fonction clé : train_test_split**

La mise à l'échelle / Normalisation (sklearn.preprocessing) La mise à l'échelle est capitale pour tous les algorithmes qui se basent sur le calcul des distances géométriques, comme le KNN. En revanche, elle n'est pas indispensable en régression linéaire.

- Les outils clés: StandardScaler, et min-max scaler :

- StandardScaler : transforme les données pour que la moyenne soit égale à 0 et l'écart-type soit égal à 1. Les valeurs obtenues peuvent tout à fait être négatives (ex: -1.5) ou supérieures à 1 (ex: 2.3).
- Min-max scaler : est l'outil qui ramène strictement les données dans l'intervalle entre 0 et 1 (en transformant la valeur minimale en 0 et la valeur maximale en 1).

Choix de l'algorithme Dans le cadre de ce cours, il s'agit de **REGRESSION LINEAIRE**.

La classe clé : **sklearn.linear_model**

La mesure d'efficacité (sklearn.metrics) Une fois les prédictions faites, il faut mesurer si le modèle s'est souvent trompé. On utilise des outils très spécifiques pour valider la performance clinique d'un test.

- Les outils clés :
- r2_score (R^2) pour évaluer la proportion de la variance expliquée par les variables indépendantes. Plus elle est proche de 1, plus le modèle est meilleur.
- mean_squared_error (MSE) pour mesurer la moyenne des carrés des erreurs de prédiction (qui pénalise fortement les grands écarts entre la réalité et la prédiction). On compare sa valeur aux valeurs de la target plus elle est petite par rapport à ce qui s'observe au niveau de la cible (Target), plus le modèle est meilleur.

1.2.8 Cas pratique : En lien avec les réalités de l'hôpital

- Principe d'analogie : Un médecin sait par expérience que plus un facteur de risque augmente (ex : le poids, l'âge ou la dose d'un produit), plus un paramètre biologique a tendance à évoluer de manière proportionnelle. La régression linéaire fait exactement la même chose : **elle modélise des tendances globales**.
- Définition simple : La régression linéaire est un algorithme qui prédit une valeur chiffrée continue (ex : la tension artérielle exacte ou le niveau de glycémie) pour un nouveau patient en s'appuyant sur l'historique médical général de la base de données. Le concept clé : **La "Ligne de tendance" et les "Coefficients d'impact."**
- L'ajustement de la droite (Moindres Carrés): Il permet d'ajuster que l'algorithme ne regarde pas de petits groupes de voisins locaux, mais analyse tous les patients passés en même temps pour tracer la ligne idéale.
  - La méthode des moindres carrés: On ajuste la droite pour minimiser au maximum les erreurs (les écarts) entre les vrais patients et la ligne.
  - La décision finale **(la prédiction)** se fait par un calcul mathématique direct en injectant les caractéristiques du patient dans l'équation de la droite.
- La notion d'impact (Poids des critères) : En médecine, chaque caractéristique clinique a une influence plus ou moins forte sur le résultat final.
  - Variables: Âge, IMC (Indice de Masse Corporelle), durée des symptômes, posologie.
  - L'algorithme calcule un coefficient β_i pour chaque critère afin de quantifier son importance. Par exemple, il détermine de combien de points exacts la tension artérielle augmente pour chaque point d'IMC supplémentaire.

1.3 PRATIQUES

1.3.1 IMPORTATION DES PACKAGES

[1]:
```
# LES PACKAGES
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
import statsmodels.api as sm
from sklearn.metrics import mean_squared_error, r2_score
```

1.3.2 LES VARIABLES

Nous allons générer des données pour 100 patients pour faire l'application de la régression linéaire.

[2]:
```
np.random.seed(42)
n_patients = 100

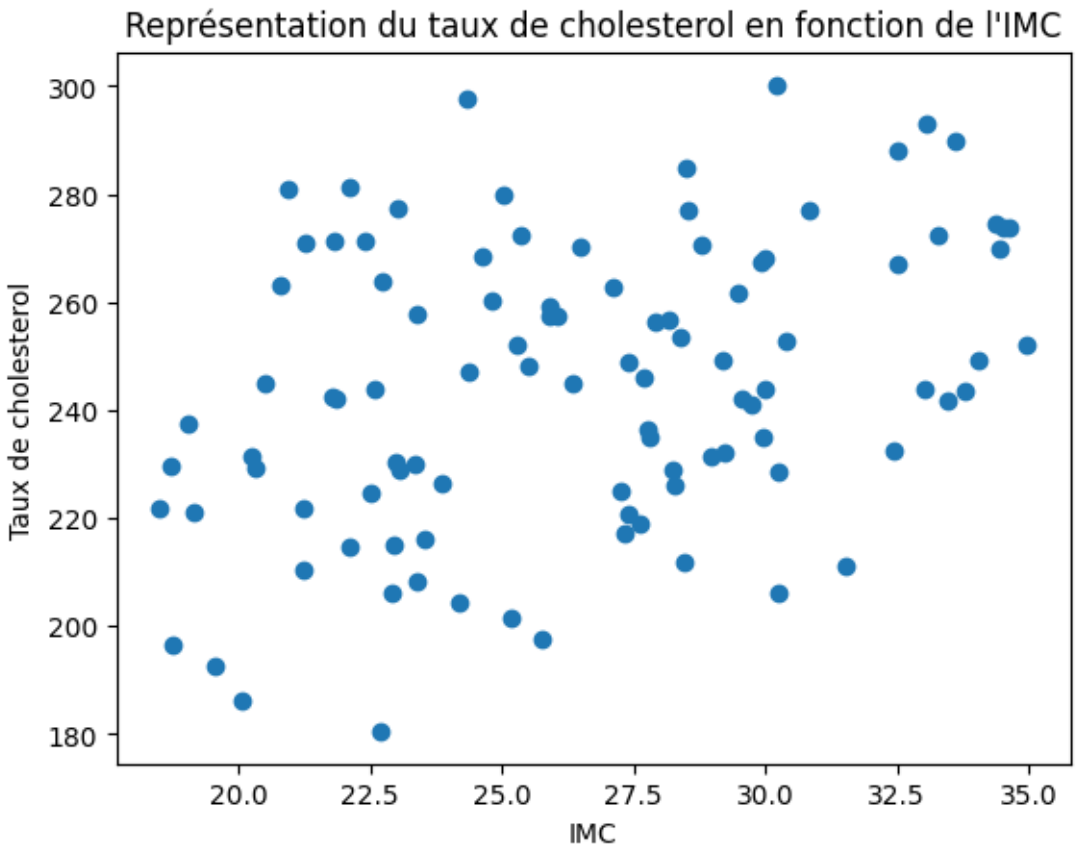
# Variables explicatives (Features)
age = np.random.randint(20, 80, size=n_patients)
imc = np.random.uniform(18.5, 35.0, size=n_patients)
bruit_biologique = np.random.normal(0, 15, size=n_patients)

# Variable dépendante (Target) : Cholestérol
cholesterol = 120 + (1.2 * age) + (2.5 * imc) + bruit_biologique

# Structuration des données
X = pd.DataFrame({"Age": age, "IMC": imc})
y = cholesterol

# Représentation du graphique de Y en fonction X
plt.scatter(X["IMC"],y)
plt.title("Représentation du taux de cholesterol en fonction de l'IMC")
plt.xlabel("IMC")
plt.ylabel("Taux de cholesterol")
```

[2]:
```
Text(0, 0.5, 'Taux de cholesterol')
```



Après avoir visualisé les données, on va séparer le jeu de données en échantillon test et entrainement

1.3.3 ECHANTILLON TRAIN ET TEST

[3]:
```
# Séparation : 80% pour l'entraînement, 20% pour le test
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.20, random_state=42
)
```

COMMENTAIRE A la vue du graphique, on peut soupçonner une tendance linéaire croissante à la hausse.

1.3.4 ENTRAÎNEMENT DE LA REGRESSION LINEAIRE AVEC SKLEARN

[4]:
```
modele = LinearRegression()
# Ajustement / Entraînement du modèle
modele.fit(X_train, y_train)
```

[4]:
```
LinearRegression()
```

[5]:
```
y_pred_1= modele.predict(X_test)
print(f"Le R_carré de notre modèle : {r2_score(y_test, y_pred_1):.4f}")
```

```
Le R_carré de notre modèle : 0.7702
```

COMMENTAIRE Avec le modèle du package sklearn, notre modèle donne un score de 0.7702, les variables âges et IMC, explique plus de 75%, le taux de cholesterole.

1.3.5 ENTRAÎNEMENT DE LA REGRESSION LINEAIRE AVEC STATSMODELS

[6]:
```
# Étape obligatoire pour statsmodels : ajouter la colonne pour Bêta_0
X_train_const = sm.add_constant(X_train)

# Entraînement du modèle MCO sur le groupe Train
modele_sm = sm.OLS(y_train, X_train_const).fit()

# Affichage du rapport statistique complet d'entraînement
print(modele_sm.summary())
```

```
                            OLS Regression Results
==============================================================================
Dep. Variable:                      y   R-squared:                       0.648
Model:                            OLS   Adj. R-squared:                  0.639
Method:                 Least Squares   F-statistic:                     70.87
Date:                Sat, 31 Oct 2026   Prob (F-statistic):           3.49e-18
Time:                        06:23:35   Log-Likelihood:                -331.92
No. Observations:                  80   AIC:                             669.8
Df Residuals:                      77   BIC:                             677.0
Df Model:                           2
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
const        132.4651     11.859     11.170      0.000     108.851     156.079
Age            1.0454      0.097     10.789      0.000       0.852       1.238
IMC            2.2766      0.389      5.857      0.000       1.503       3.051
==============================================================================
Omnibus:                        0.477   Durbin-Watson:                   1.656
Prob(Omnibus):                  0.788   Jarque-Bera (JB):                0.607
Skew:                          -0.161   Prob(JB):                        0.738
Kurtosis:                       2.720   Cond. No.                         400.
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly
specified.
```

COMMENTAIRE:

Avec le modèle du package statsmodels, notre modèle donne un score de 0.639, les variables âges et IMC, explique plus de 60%, le taux de cholesterole.

- A IMC constante, une augmentation d'une unité de la variable âge entraine une augmentation de 1.0454 du taux de cholesterol.
- A age constant, une augmentation d'une unité de la variable IMC entraine une augmentation de 2.2766 du taux de cholesterol.

De plus, les tests de diagnostics valident la modélisation: le test de Jarque-Bera(p-value=0,738) confirme la normalité des résidus, garantissant la validité des conclusions statistiques.

1.3.6 NOTE TRES IMPORTANTE

- Sklearn (Machine Learning) : Son but principal est la prédiction et la généralisation sur de nouvelles données. Évaluer son score R^2 sur l'échantillon Test (les données que le modèle n'a jamais vues) est la règle d'or pour vérifier s'il est performant en situation réelle.
- Statsmodels (Statistique classique) : Son but principal est l'explication et l'inférence. Le rapport complet (le .summary()) sert à analyser à quel point le modèle mathématique s'ajuste bien aux données observées et si les coefficients sont statistiquement significatifs (p-value est inférieur à 0.05). Il est donc tout à fait logique de regarder le R^2 ajusté d'entraînement ici.

1.3.7 PRÉDICTIONS ET MÉTRIQUES D'ÉVALUATION

[7]:
```
# Faire les prédictions sur les nouveaux patients (Test)
y_pred_test = modele.predict(X_test)

# Extraire les coefficients pour votre graphique de la droite
b0 = modele.intercept_
b_age = modele.coef_[0]  # Coefficient de l'Âge
b_imc = modele.coef_[1]  # Coefficient de l'IMC
```

1.3.8 TRACAGES DU NUAGES DE POINTS SUR L'ECHANTILLON TEST AVEC LA DROITE D'AJUSTEMENT

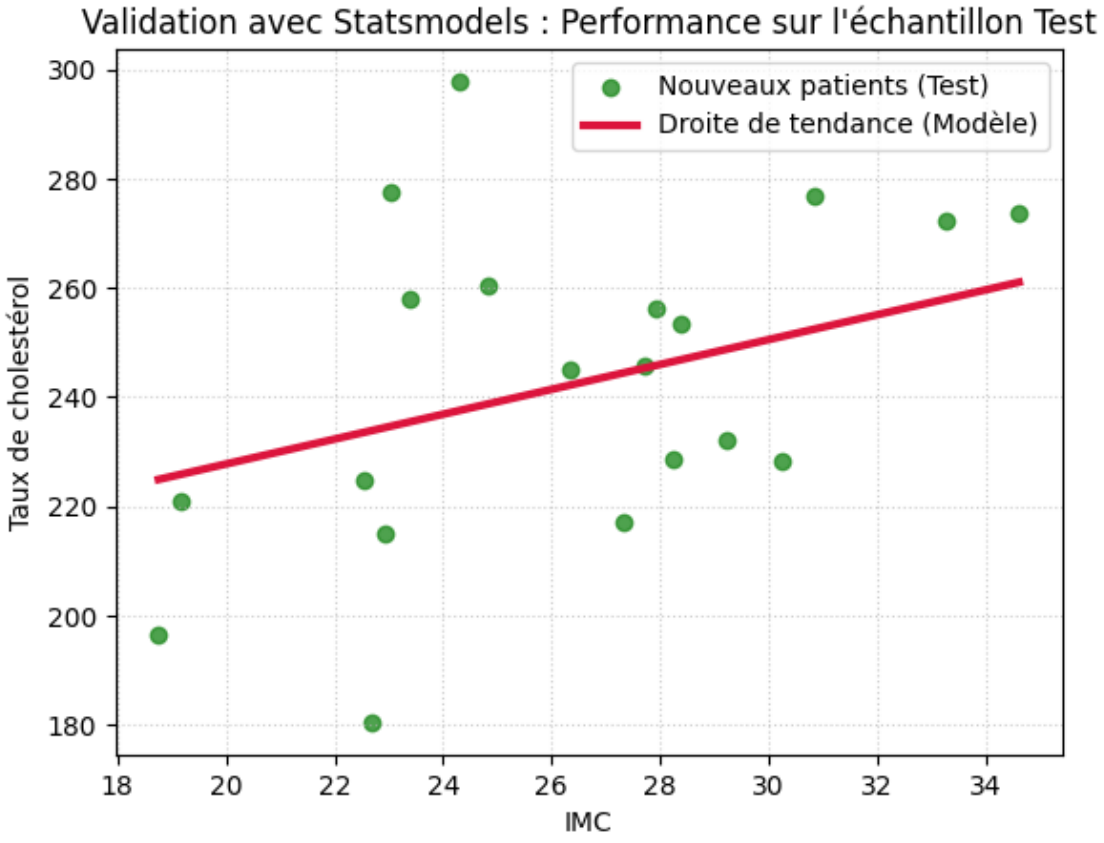
[8]:
```
# Nuage de points des 20 nouveaux patients (Test)
plt.scatter(
    X_test["IMC"],
    y_test,
    color="forestgreen",
    alpha=0.8,
    label="Nouveaux patients (Test)",
)

# Calcul de la droite de tendance pour l'IMC (en fixant l'âge à sa moyenne de␣
 ↪test)
age_moyen_test = X_test["Age"].mean()
x_droite = np.array([X_test["IMC"].min(), X_test["IMC"].max()])
y_droite = (b0 + b_age * age_moyen_test) + (b_imc * x_droite)
```

```python
# Tracé de la ligne droite finale
plt.plot(
    x_droite,
    y_droite,
    color="crimson",
    linewidth=3,
    label="Droite de tendance (Modèle)",
)

# Habillage clinique du graphique
plt.title("Validation avec Statsmodels : Performance sur l'échantillon Test")
plt.xlabel("IMC")
plt.ylabel("Taux de cholestérol")
plt.legend()
plt.grid(True, linestyle=":", alpha=0.6)

plt.show()
```



1.3.9 LIMITES DU MODELE DE REGRESSION LINEAIRE

- Relation figée : Elle suppose une relation uniquement en ligne droite, incapable de capturer les courbes de la réalité.
- Sensibilité aux extrêmes : les valeurs aberrantes (outlier) sont sujettes à fausser totalement la trajectoire de la ligne.
- Piège de la causalité : Elle démontre une simple corrélation numérique, mais ne prouve jamais un lien de cause à effet.
- Risque d'extrapolation : Ses prédictions deviennent très peu fiables dès qu'on sort de la fourchette des données observées.
- Instabilité (multicolinéarité) : Le modèle s'embrouille et devient instable lorsque les variables explicatives sont trop corrélées entre elles.

1.3.10 REFRENCES BIBLIOGRAPHIQUES

- Gilbert Saporta , Probabilités, analyse des données et statistique (3ème édition), Éditions Technip, Paris